



# Redes Neurais Competitivas

Prof. Fabio M Simoes de Souza Centro de Matemática, Computação e Cognição

## Livros






## Aprendizagem Não Supervisionada

- A resposta correta (target) não é conhecida de antemão.
- Como treinar a rede nesse caso, se não existe um sinal de erro?
- Tentar identificar similaridades entre as entradas de maneira a categoriza-las em diferentes conjuntos (clusters).

# What K-Means does for you



STEP 1: Choose the number K of clusters



STEP 2: Select at random K points, the centroids (not necessarily from your dataset)



STEP 3: Assign each data point to the closest centroid 
That forms K clusters



STEP 4: Compute and place the new centroid of each cluster




STEP 5: Reassign each data point to the new closest centroid.


If any reassignment took place, go to STEP 4, otherwise go to FIN.




Your Model is Ready

• Classifique esses pontos em clusters







STEP 3: Assign each data point to the closest centroid → That forms K clusters





STEP 3: Assign each data point to the closest centroid - That forms K clusters





STEP 3: Assign each data point to the closest centroid - That forms K clusters


























































Algoritmo pode ser aplicado em dados de n dimensões!




#### Rede Neural K-Means

- O treinamento da rede é feito pela movimentação dos neurônios através do ajuste dos pesos
- Uma rede neural de uma única camada consegue implementar o algoritmo K-Means (K neurônios saída)



# Espaço de Pesos

O Posição dos neurônios no espaço de pesos.




## Espaço de Entrada


- Também é possível calcular a posição dos neurônios no espaço de entrada (x1, x2, x3), usando a distância euclidiana.
- Pode-se calcular as distâncias entre os neurônios e entradas para determinar quais neurônios estão mais próximos ou distantes.
- Neurônios próximos representariam um mesmo estímulo.


$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}.$$

## Algoritmo K-Means

- É possível alinhar o espaço de pesos e o espaço de entrada da rede neural de maneira a criar uma representação das entradas na rede.
- Algoritmo K-Means: cria-se K categorias e depois se alinha as categorias (clusters) aos dados de entrada.
- O centro de cada cluster é calculado pela média das distâncias das entradas mais próximas àquele cluster.







#### Rede Neural K-Means

- Localiza-se os centros dos clusters no espaço de pesos
- Posiciona-se os neurônios nesses lugares através do treinamento da rede
- A posição de cada neurônio é a sua posição no espaço de pesos.
- Decide-se quais clusters estão mais próximos ao se calcular a distância de cada neurônio em relação à todos os clusters.
- Para cada entrada, determina-se a distância entre o neurônio no espaço de pesos e a entrada.

## Aprendizado Competitivo

- Na camada de saída, os neurônios competem para ativar, de forma que apenas um neurônio por vez é ativado na camada se saída.
- Cada neurônio representa uma categoria (K neurônios)
- Para cada entrada, apenas o neurônio com máxima ativação h é o vencedor.
- O neurônio que vence é aquele mais próximo da entrada atual.
- Treinamento: move-se o neurônio vencedor para mais perto da entrada atual. Apenas os pesos dos vencedores são alterados
- O vetor de pesos é normalizado entre 0 e 1 para evitar distorções numéricas na competição (pesos muito grandes (10, 1000 etc), sempre iriam ganhar.

$$\Delta w_{ij} = \eta(x_j - w_{ij}),$$

# Algoritmo K-Means

#### The On-Line k-Means Algorithm

#### Initialisation

- choose a value for k, which corresponds to the number of output nodes
- initialise the weights to have small random values


#### • Learning

- normalise the data so that all the points lie on the unit sphere
- repeat:
  - \* for each datapoint:
    - compute the activations of all the nodes
    - pick the winner as the node with the highest activation
    - · update the weights using Equation (14.7)  $\Delta w_{ij} = \eta(x_j w_{ij}),$
  - until number of iterations is above a threshold

#### Usage

- for each test point:
  - \* compute the activations of all the nodes
  - pick the winner as the node with the highest activation

#### Clustering



- Aprender informações à respeito da organização dos dados (distribuição não paramétrica)
- Iris dataset (tipo de flor).
- 3 Classes: Espécies Iris Setosa, Iris Versicolour,
   Iris Virginica

4 atributos: comprimento e largura da sépala (cm), comprimento e largura da pétala (cm).








- o net = kmeansnet.kmeans(3,train)
- net.kmeanstrain(train)
- cluster = net.kmeansfwd(test)
- print cluster
- [ 0. 0. 0. 0. 0. 1. 1. 1. 1. 2. 1. 2. 2. 2. 0. 1. 2. 1. 0.
- 0 1. 2. 2. 2. 1. 1. 2. 0. 0. 1. 0. 0. 0. 0. 2. 0. 2. 1.]
- o print iris[3::4,4]
- [ 1. 1. 1. 1. 1. 2. 2. 2. 1. 0. 2. 0. 0. 0. 1. 1. 0. 2. 2.
- O 2. 0. 0. 0. 2. 2. 0. 1. 2. 1. 1. 1. 1. 1. 0. 1. 0. 2.]


- Compressão de dados
- Compressão de uma imagem tiff com milhares
   de cores para uma imagem RGB com apenas 16 cores.
- Usa-se K-means com 16 clusters.
- A imagem original tem as cores dos pixels correspondentes a cada cluster substituídas, gerando a compressão.






#### **Mapas Corticais**


- Organização neocortical
- Mapas de dominância ocular no córtex reveladas por fMRI
- Representação topográfica das áreas sensoriais sensíveis a pressão no córtex somatosensorial
- Atributos de entrada próximos são representados em areas corticais adjacentes






#### Lesão Cortical


- Reorganização dos mapas corticais após uma lesão em macacos
- Como essas reorganizações ocorrem?







J. Neurophysiol. 79: 2119–2148, 1998.

- Rede do mapa auto-organizado de Kohonen
- Inspirada na representação de mapas sensoriais no córtex cerebral





Mudando a visualização






Pesos são as coordenadas espaciais do nó no espaço de pesos







Calcule o nó com a menor distância do dado de entrada




Competição: calcule o nó com a menor distância dos dados de entrada



#### Exemplos







MACHINE LEARNING: An Algorithmic Perspective

https://www.superdatascience.com/pages/deep-learning

- Representação do espaço de entrada no espaço do mapa
- Neurônios próximos representam atributos similares
- Aprendizagem não supervisionada




- O mapa se auto-organiza movendo-se na direção dos dados
- Os nós vencedores aumentam o próprio peso e o peso dos outros nós em seu raio de ação, movendo-se na direção dos dados
- Existe competição entre os nós com intersecção de raio de ação
- O raio de ação dos nós vencedores é gradativamente reduzido ao longo do processo




https://en.wikipedia.org/wiki/Self-organizing map

Auto-organização do mapa


Nós vencedores




Raio de ação




Raio de ação



Raio de ação



Formação do mapa



#### Algoritmo do Mapa Auto-Organizado

#### The Self-Organising Feature Map Algorithm

#### Initialisation

- choose a size (number of neurons) and number of dimensions d for the map
- either:
  - \* choose random values for the weight vectors so that they are all different OR
  - set the weight values to increase in the direction of the first d principal components of the dataset

#### Learning

- repeat:
  - \* for each datapoint:
    - select the best-matching neuron n<sub>b</sub> using the minimum Euclidean distance between the weights and the input,

$$n_b = \min_j \|\mathbf{x} - \mathbf{w}_j^T\|.$$
 (14.8)

\* update the weight vector of the best-matching node using:

$$\mathbf{w}_{j}^{T} \leftarrow \mathbf{w}_{j}^{T} + \eta(t)(\mathbf{x} - \mathbf{w}_{j}^{T}),$$
 (14.9)

#### Algoritmo do Mapa Auto-Organizado

where  $\eta(t)$  is the learning rate.

\* update the weight vector of all other neurons using:

$$\mathbf{w}_{j}^{T} \leftarrow \mathbf{w}_{j}^{T} + \eta_{n}(t)h(n_{b}, t)(\mathbf{x} - \mathbf{w}_{j}^{T}),$$
 (14.10)

where  $\eta_n(t)$  is the learning rate for neighbourhood nodes, and  $h(n_b, t)$  is the neighbourhood function, which decides whether each neuron should be included in the neighbourhood of the winning neuron (so h = 1 for neighbours and h = 0 for non-neighbours)

- \* reduce the learning rates and adjust the neighbourhood function, typically by η(t+1) = αη(t)<sup>k/kmax</sup> where 0 ≤ α ≤ 1 decides how fast the size decreases, k is the number of iterations the algorithm has been running for, and k<sub>max</sub> is when you want the learning to stop. The same equation is used for both learning rates (η, η<sub>n</sub>) and the neighbourhood function h(n<sub>b</sub>,t).
- until the map stops changing or some maximum number of iterations is exceeded

#### Usage

- for each test point:
  - \* select the best-matching neuron n<sub>b</sub> using the minimum Euclidean distance between the weights and the input:

$$n_b = \min_j \|\mathbf{x} - \mathbf{w}_j^T\| \qquad (14.11)$$




Fig. 4. Weight vectors during the ordering process, onedimensional array.







Fig. 3. Weight vectors during the ordering process, twodimensional array.





3D







Fig. 5. Representation of three-dimensional (uniform) density functions by two-dimensional maps.


- Mapas auto-organizados
- rij é a ativação dos neurônios




Fundamentals of Computational Neuroscience


- Regra de aprendizagem
- O vencedor leva tudo: neurônio vencedor aumenta o próprio peso e os pesos dos vizinhos em sua área de influência
- rij\* é a ativação do neurônio vencedor


$$\Delta c_{ijk} = \epsilon r_{ij}^* (r_i^{\text{in}} - c_{ijk}),$$





```
"" Two dimensional self-organizing feature map at la Kohonen
      clear; nn=10; lambda=0.2; sig=2; sig2=1/(2*sig^2);
      [X,Y]=meshgrid(1:nn,1:nn); ntrial=0;
 4
      % Initial centres of prefered features:
      c1=0.5-.1*(2*rand(nn)-1):
     c2=0.5-.1*(2*rand(nn)-1);
 8
     %% training session
      while(true)
10
11
         if(mod(ntrial,100)==0) % Plot grid of feature centres
             clf; hold on; axis square; axis([0 1 0 1]);
12
             plot(c1,c2,'k'); plot(c1',c2','k');
13
             tstring=[int2str(ntrial) ' examples']; title(tstring);
14
15
             waitforbuttonpress;
16
         end
17
         r_in=[rand;rand];
         r=exp(-(c1-r_in(1)).^2-(c2-r_in(2)).^2);
18
         [rmax,x_winner]=max(max(r)); [rmax,y_winner]=max(max(r));
19
         r=exp(-((X-x\_winner).^2+(Y-y\_winner).^2)*sig2);
20
21
        c1=c1+lambda*r.*(r_in(1)-c1);
22
         c2=c2+lambda*r.*(r_in(2)-c2);
23
         ntrial=ntrial+1:
24
      end
```






























r1=rand; r2=rand






r1=rand; r2=rand







r1=sin; r2=cos




r1=sin; r2=cos




r1=sin; r2=tan




r1=sin; r2=tan






- Auto-organização: interação é local, gerando uma organização global (como na inteligência de abelhas e formigas)
- Neurônios vencedores atraem outros neurônios próximos no espaço de pesos.
- Neurônios vencedores repelem neurônios distantes através do uso de pesos negativos.
- Neurônios muito distantes são ignorados (representam outros atributos)
- Função Chapéu Mexicano




- Mapas auto-organizados detém a topologia dos dados de entrada (como uma máscara)
- Mapas auto-organizados revelam correlações que não são fácilmente identificados
- Mapas auto-organizados classificam os dados sem supervisão
- Não precisa de target-vector e backpropagation para treinamento da rede
- Não existem conexões laterais entre os nós do mapa

 Bordas circulares (anel e torus) são utilizadas para minimizar efeitos de borda.




É computacionalmente eficiente considerar múltiplas cópias de um mesmo mapa colocados ao redor do mapa original




#### Exemplos de Aplicações


Taxonomia: Organização do Banco de Dados Iris




### Exemplos de Aplicações

Taxonomia: cluster hierárquico








https://sci2s.ugr.es/keel/pdf/algorithm/articulo/19 90-Kohonen-PIEEE.pdf

#### Organização de Atributos

Nível de desenvolvimento dos países

A	A.	В	C	D	E
1	Country	Country C	Health Ex	Education E	Inflation
2	Aruba	ABW	9.418971	5.92467022	-2.13637
3	Afghanist	AFG	4.371774		-8.28308
4	Angola	AGO	5.791339		13.73145
5	Albania	ALB	6.75969		2.280502
6	Andorra	AND	4.57058	3.1638701	
7	Arab Wor	ARB	4.049924		3.524814
8	United Ar	ARE	7.634758		
9	Argentina	ARG	4.545323	4.88997984	6.282774
10	Armenia	ARM		3.84079003	3.406767
11	American	ASM	4.862062		
12	Antigua a	ATG	9.046056	2.55447006	-0.55016
13	Australia	AUS	11.19444	5.09262991	1.820112
14	Austria	AUT	5.85024	5.7674098	0.506313
15	Azerbaija	AZE	6.964187	3.22430992	1.401056
16	Burundi	BDI	10.39434	6.3197999	10.98147
17	Belgium	BEL	4.46431	6.41535997	-0.05315
18	Benin	BEN	7.405431	4.22204018	2.15683





http://www.ai-junkie.com/ann/som/som5.html


http://www.cis.hut.fi/

https://www.superdatascience.com/pages/deep-learning

#### Detecção de Fraude Cartão Crédito

- Casos são raros
- Quantidade de dados disponível muito baixa para aplicar aprendizado supervisionado
- Solução possível através de clustering dos dados por mapas auto-organizados
- Dataset:
  - http://archive.ics.uci.edu/ml/datasets/statlog+(australian+cred
    it+approval)
- As fraudes são os outliers (os pontos fora da curva, aqueles que não seguem as regras)

## Detecção de Fraude Cartão Crédito



## Até a Próxima Aula!